

Отборочное задание Data Engineer

Мы рады пригласить вас принять участие в отборочном задании в мастерскую Astra для участия в проекте по тематике “Применение ИИ в задачах сбора и обработки закупочной информации”. Задание направлено на проверку ваших навыков в области работы с данными.

Вам предлагается выполнить серию практических заданий, посвященных проектированию базы данных и построению процесса сбора, обработки и хранения данных.

Условия участия

1. Количество заданий: Задание разбито на три части. Вы можете выбрать любое количество подзаданий для выполнения, начиная с одного. Чем больше подзаданий вы выполните, тем выше ваши шансы на успешное прохождение отбора.
2. Формат сдачи работ: Исходный код должен быть размещён на платформе на платформе github.com.
3. Критерии оценивания: Оценка будет основываться на количестве выполненных заданий, качестве кода, полноте реализации и правильности предложенных решений.
4. Срок подачи работ: Работы принимаются до _____.

Задание

Часть 1: Проектирование

Зафиксируйте свои рассуждения в файле TASK.MD.

Задание 1.0: Анализ исходных данных

1. Загрузите данные, посвященные продаже строительных материалов (<https://www.kaggle.com/datasets/sergionefedov/us-building-materials-sales-transactions-20192024>).
2. Изучите структуру датасетов продаж и макроэкономических показателей.
3. Определите связи между сущностями, возможные проблемы качества исходных данных подобной структуры. Опишите их.

Задание 1.1: Схема базы данных

Выберите архитектуру хранения данных и постройте схему таблиц БД со связями. Следует ли придерживаться третьей нормальной формы или выгоднее денормализация? Обоснуйте свой выбор и опишите преимущества и недостатки.

Задание 1.2 Выбор СУБД

Какую СУБД можно считать наиболее подходящей для полученной схемы? Обоснуйте свой выбор и приведите сравнение с одной или более альтернативами.

Задание 1.3: Структура ETL-процесса

1. Сколько промежуточных слоев данных следует использовать? Какова будет структура данных на них? Какие преобразования будут происходить? Опишите общую схему.

Часть 2: Реализация ETL-процесса

Задание 1.1: Разработка основного пайплайна

1. Реализуйте скрипт, разделенный на логические этапы извлечения, обработки и загрузки.
2. Настройте валидацию входящих данных. Проверяйте типы данных, корректность диапазонов, отсутствие критичных пропусков.

Задание 1.2: Инкрементальные обновления

1. Реализуйте поддержку добавления новых данных в существующий массив. Обеспечьте идемпотентность пайплайна и возможность обновления исторических данных.

Часть 3: Сопровождаемость проекта

Задание 3.1: Отказоустойчивость

1. Пайплайн не должен падать в случае появления некорректных строк. Реализуйте изоляцию таких строк в отдельную таблицу с описанием причины ошибки.
2. Поддержите возможность отката транзакций записи в БД в случае критических ошибок.
3. Напишите базовые тесты, проверяющие корректность трансформаций данных.

Задание 3.2: Документирование

1. Опишите общую структуру проекта и порядок действий для развертывания в README.MD.
2. Добавьте докстринги всем основным классам и функциям проекта.